

TITRE PROFESSIONNEL DEVELOPPEUR EN INTELLIGENCE ARTIFICIELLE
RNCP B3 - Simplon / ECE Paris

MODELE CONCEPTUEL DE DONNEES (MCD)

Compétence C4 - Créer une base de données dans le respect du RGPD

Projet : Inflation Tracker France

Formalisme : Merise (entités-associations, cardinalités)

Auteur : Alberto BONGUELE

Date : Juillet 2026

Issue GitHub : (C4 — base de données)

SOMMAIRE

1. Entités et attributs	3
2. Associations et cardinalités Merise.....	4
3. Contrainte d'intégrité fonctionnelle (CIF).....	4
4. Correspondance MCD vers MPD	4
5. Choix de base de données	5
6. Diagramme entités-associations.....	6

1. Entités et attributs

Le modelé conceptuel du projet *inflation-tracker* comporte 5 entités représentant les objets du domaine métier. Les tables de staging ETL (**ecb_hicp_raw**, **insee_ipc**, **datagouv_ipc**, **eurostat_bulk**) sont des artefacts techniques du pipeline et n'apparaissent pas dans le MCD — elles alimentent `inflation_unified` via `aggregate_clean.py`.

Entité	Identifiant	Attributs	Description
SOURCE	nom	type_collecte, base_ref	Source de données publiques (ECB, INSEE, DATAGOUV, EUROSTAT, OPENFOODFACTS)
CATEGORIE_COICOP	code (00-12)	Libelle	Les 13 grandes catégories IPC niveau 1 de la nomenclature COICOP
PAYS	code_iso	aucun	Code pays ISO 3166-1 alpha-2 (FR, DE, AT...)
OBSERVATION_IPC	id (UUID)	date_obs, valeur	Un point de mesure de l'indice IPC a une date, pour un pays, une catégorie et une source
PRIX_ALIMENTAIRE	id (UUID)	produit, prix_unitaire, date_collecte, url	Prix relevé via Open Food Facts (hors table unifiée, sémantique différente des indices)

Détail des entités

SOURCE

- nom (PK) : ECB | INSEE | DATAGOUV | EUROSTAT | OPENFOODFACTS
- type_collecte : API | CSV | BigData | Scraping
- base_ref : 2015 (INSEE, ECB, EUROSTAT) | 2025 (DATAGOUV)

CATEGORIE_COICOP

- code (PK) : 00 a 12 (niveau 1 COICOP)
- libelle : ex. 01 - Alimentation et boissons non alcoolisées

PAYS

- code_iso (PK) : ex. FR, DE, AT, BE

OBSERVATION_IPC

- id (PK, UUID) : identifiant unique généré par `gen_random_uuid()`
- date_obs : 1er jour du mois (ex. 2024-01-01)
- valeur : indice IPC en NUMERIC (10,4) (ex. 119.8000)
- Clés étrangères : source, catégorie (code COICOP), pays (code_iso)

PRIX_ALIMENTAIRE

- id (PK, UUID)

- produit : nom du produit (ex. Pomme Cripps Pink)
- prix_unitaire : prix en euros (ex. 4.29)
- date_collecte : date du relevé de prix
- url : lien produit Open Food Facts
- Clés étrangères : source (OPENFOODFACTS), catégorie (code COICOP)

2. Associations et cardinalités Merise

Association	Cardinalités	Lecture
SOURCE — FOURNIT — OBSERVATION_IPC	(1,1) — (0,N)	Une observation provient d'exactly 1 source. Une source fournit 0 a N observations.
CATEGORIE_COICOP — CLASSIFIE — OBSERVATION_IPC	(1,1) — (0,N)	Une observation appartient a exactly 1 catégorie COICOP. Une catégorie regroupe 0 a N observations.
PAYS — CONCERNE — OBSERVATION_IPC	(1,1) — (0,N)	Une observation concerne exactly 1 pays. Un pays est associe a 0 a N observations.
SOURCE — COLLECTE — PRIX_ALIMENTAIRE	(1,1) — (0,N)	Un prix alimentaire est collecte par 1 source (OPENFOODFACTS). Une source collecte 0 a N prix.
CATEGORIE_COICOP — CLASSE — PRIX_ALIMENTAIRE	(1,1) — (0,N)	Un prix alimentaire appartient a 1 catégorie. Une catégorie regroupe 0 a N prix.

Lecture globale : l'entité centrale du modèle est OBSERVATION_IPC. Elle est qualifiée par trois dimensions indépendantes : la source qui a produit la mesure, la catégorie COICOP à laquelle elle appartient, et le pays auquel elle se rapporte. Cette structure en étoile est la traduction directe du schéma en flocon de la table inflation_unified dans le MPD.

3. Contrainte d'intégrité fonctionnelle (CIF)

Sur OBSERVATION_IPC :

La combinaison (date_obs, pays, catégorie, source) est unique. Il ne peut exister qu'une seule observation par date, pays, catégorie et source.

Implémentation dans le MPD :

UNIQUE (date_obs, pays, catégorie, source) sur la table inflation_unified.

Cette contrainte garantit l'idempotence du pipeline ETL. Si aggregate_clean.py est rejoue plusieurs fois, les doublons sont ignorés via ON CONFLICT DO NOTHING. La table reste propre sans nettoyage manuel.

4. Correspondance MCD vers MPD

Le passage du MCD conceptuel au MPD physique implique des choix d'implémentation documentés ci-dessous.

Entité MCD	Table(s) MPD	Remarque
OBSERVATION_IPC	inflation_unified	Table centrale unifiée — toutes sources agrégées
SOURCE	colonne source + base_ref dans inflation_unified	Dénormalise — choix performance, pas de jointure supplémentaire
CATEGORIE_COICOP	CTE coicop_ref dans aggregate_clean.py	Référentiel embarqué dans le SQL d'agrégation, pas de table séparée
PAYS	colonne pays dans inflation_unified	Dénormalise — valeur FR sur 95% des lignes
PRIX_ALIMENTAIRE	openfoodfacts	Table séparée — sémantique prix bruts différente des indices IPC

Tables de staging ETL absentes du MCD :

Les 4 tables **ecb_hicp_raw**, **insee_ipc**, **datagouv_ipc** et **eurostat_bulk** sont des zones d'atterrissage temporaires du pipeline ETL. Elles ne représentent pas des entités du domaine métier. Elles alimentent **inflation_unified** via **aggregate_clean.py** et disparaissent conceptuellement après agrégation. Leur présence dans le **schema.sql** est un choix technique de traçabilité, pas un choix de modélisation.

5. Choix de base de données

Système retenu : PostgreSQL 16

Justifications :

- ACID garanti sur 3 680 000 lignes avec transactions ETL idempotentes via ON CONFLICT DO NOTHING
- Type NUMERIC(10,4) sans erreur d'arrondi flottant sur les indices IPC — critique pour la fiabilité des calculs de variation
- UUID avec gen_random_uuid() natif, pas de séquence à gérer
- Support des index partiels et des contraintes UNIQUE composites (CIF)
- Compatibilité native avec SQLAlchemy (pipeline Python) et FastAPI
- Docker officiel PostgreSQL 16 disponible, reproductible en une commande


Pourquoi pas **MySQL** ou **SQLite** :

- **SQLite** : pas de type UUID natif, pas de ON CONFLICT DO NOTHING standard, pas adapté à un volume de 3,68M lignes
- **MySQL** : type NUMERIC moins strict sur les arrondis, comportement AUTO_INCREMENT moins prédictible que UUID

Scripts associés :

- **Schema physique** : src/database/schema.sql
- **Script d'import** : src/database/import_data.py

6. Diagramme entités-associations



Code source du diagramme (format Mermaid, renderisable sur mermaid.live) :

erDiagram

```
SOURCE {
    string nom PK
    string type_collecte
    string base_ref
}
CATEGORIE_COICOP {
    string code PK
    string libelle
}
PAYS {
    string code_iso PK
}
OBSERVATION_IPC {
    uuid id PK
    date date_obs
    decimal valeur
}
PRIX_ALIMENTAIRE {
    uuid id PK
}
```

```
string produit
décimal prix_unitaire
date date_collecte
string url
}
SOURCE ||--o{ OBSERVATION_IPC : "fournit"
CATEGORIE_COICOP ||--o{ OBSERVATION_IPC : "classifie"
PAYS ||--o{ OBSERVATION_IPC : "concerne"
SOURCE ||--o{ PRIX_ALIMENTAIRE : "collecte"
CATEGORIE_COICOP ||--o{ PRIX_ALIMENTAIRE : "classe"
```

Pour générer le diagramme visuellement : coller le code sur <https://mermaid.live> et faire une capture d'écran du résultat.